UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

INSTITUTO DE INFORMÁTICA

INF01017 Aprendizado de Máquina

Trabalho 1: Aprendizado Ensemble com Florestas Aleatórias

Augusto Bennemann

Fabrício Martins Mazzola

Porto Alegre, 10 de Maio de 2018

Introdução

Neste trabalho exploramos um aprendizado *ensemble*, por meio de florestas aleatórias. Para treinar o algoritmo e analisar seu desempenho utilizamos os quatro *datasets* propostos.

Inicialmente, fizemos um pré-processamento nos conjuntos de dados para padronizá-los de acordo com o formato de entrada que especificamos para nosso programa. Essas alterações foram, basicamente, incluir o nome das colunas na primeira linha e mover a coluna da classe para a última posição.

O algoritmo foi desenvolvido na linguagem Python 3. Junto a esse relatório há a versão final do código (*trabalho_1_adm.py*) e um arquivo do Jupyter (*Trabalho_1_ADM_iypnb.ipynb)* usado no desenvolvimento, que contém as mesmas funcionalidades do primeiro, mas em uma ordem um pouco diferente e com alguns testes individuais extras.

A validação cruzada estratificada foi realizada com *k = 10 folds*, conforme sugerido. Para o *bootstrap*, utilizamos 0.66 (66%) na seleção para o conjunto de treinamento. Para o número de atributos amostrados (*m*) utilizamos a raiz quadrada do número total de atributos, conforme valor padrão sugerido pela literatura.

Estruturas de dados

Para implementar a Árvore de Decisão, criamos a classe *Node*, que define um nodo que pode ter outros nodos descendentes. No caso, há um nó raíz do qual derivam, em algum nível, todos os outros nós da árvore.

Cada nó possui: um atributo (seu nome, a saber "*Temperatura"*), uma classType (a classe prevista quando é um nó folha, ou *None* caso contrário), um operador da linguagem (==, <= ou >= *); e* descendentes.

```
class Node(object):
  def __init__(self, attribute=None):
    self.attribute = attribute
    self.classType = None
    self.operator = operator.eq
    self.descendents = {}

  def addBranch(self, subAttribute, op, node):
    self.descendents[subAttribute] = node
    self.descendents[subAttribute].updateOperator(op)

  def updateClass(self, classType):
    self.classType = classType

  def updateAttribute(self, attribute):
    self.attribute = attribute

  def updateOperator(self, op):
    self.operator = op
```

Definição da classe Node

```
DiabetesPedigreeFunction: None
-> 0.16819
   BMI: None
   -> 0.46661
      Age: None
      -> 0.18263
         Glucose: None
         -> 0.53588
            Insulin: None
            -> 0.03798
               SkinThickness: None
               -> 0.09804
                  None: 0
               -> 0.09803
                  Pregnancies: None
                  -> 0.12046
                     None: 0
                  -> 0.12045
                     BloodPressure: None
                     -> 0.52323
                        None: 0
                     -> 0.52322
                        None: 0
            -> 0.03797
               None: 0
         -> 0.53587
            None: 0
      -> 0.18262
         None: 0
   -> 0.4666
      None: 0
-> 0.16818
   None: 0
```

Exemplo de árvore induzida para o conjunto de dados Diabetes

Corretude

A fim de provar a corretude, executamos o algoritmo de indução da árvore no conjunto de dados de *benchmark* fornecido. À direita, estão os valores obtidos, que conferem com o esperado.

```
Ganho para Tempo: 0.247
Ganho para Temperatura: 0.029
Ganho para Umidade: 0.152
Ganho para Ventoso: 0.048
```

Inicialmente, implementamos uma versão básica do algoritmo de indução, usando apenas o Ganho de Informação como critério de seleção. A seguir, à esquerda, está a árvore gerada nesse caso e os valores de Ganho de Informação a cada divisão de nós. Em

seguida, inserimos no algoritmo a seleção aleatória de *m* atributos. À direita está uma indução realizada por essa versão - que é a final -, também com os valores de Ganho a cada divisão.

```
Tempo: None
-> Ensolarado
   Umidade: None
   -> Alta
      None: Nao
   -> Normal
      None: Sim
-> Nublado
   None: Sim
-> Chuvoso
   Ventoso: None
   -> Falso
      None: Sim
   -> Verdadeiro
      None: Nao
```

```
Ganho para Temperatura: 0.029
Ganho para Ventoso: 0.048
Ganho para Umidade: 0.152
Ganho para Tempo: 0.247

Ganho para Ventoso: 0.02
Ganho para Temperatura: 0.571
Ganho para Umidade: 0.971

Ganho para Temperatura: 0.02
Ganho para Ventoso: 0.971
```

```
Umidade: None
-> Alta
   Ventoso: None
   -> Falso
      Tempo: None
      -> Ensolarado
         None: Nao
      -> Nublado
         None: Sim
      -> Chuvoso
         None: Sim
   -> Verdadeiro
      Temperatura: None
      -> Quente
         None: Nao
      -> Amena
         None: Sim
-> Normal
   None: Sim
```

```
Ganho para Ventoso: 0.048
Ganho para Umidade: 0.152

Ganho para Ventoso: 0.02
Ganho para Temperatura: 0.02

Ganho para Temperatura: 0.0
Ganho para Tempo: 1.0

Ganho para Temperatura: 0.252
```

Análise de desempenho

Para avaliar o desempenho do algoritmo, testamos os quatro conjunto de dados variando o parâmetro *ntree* (número de árvores) para 10, 25, 50, 75, 100 e 125. Como métrica, para os três primeiros foi utilizada a F1-measure, enquanto que para o último utilizou-se a “média da precisão macro” pois ele possui 3 classes.

1. Diabetes

F1 \ Árvores	10	25	50	75	100	125	150	200
Média	0.72	0.74	0.72	0.72	0.73	0.70	0.73	0.72
Desvio	0.05	0.03	0.05	0.04	0.04	0.03	0.03	0.04

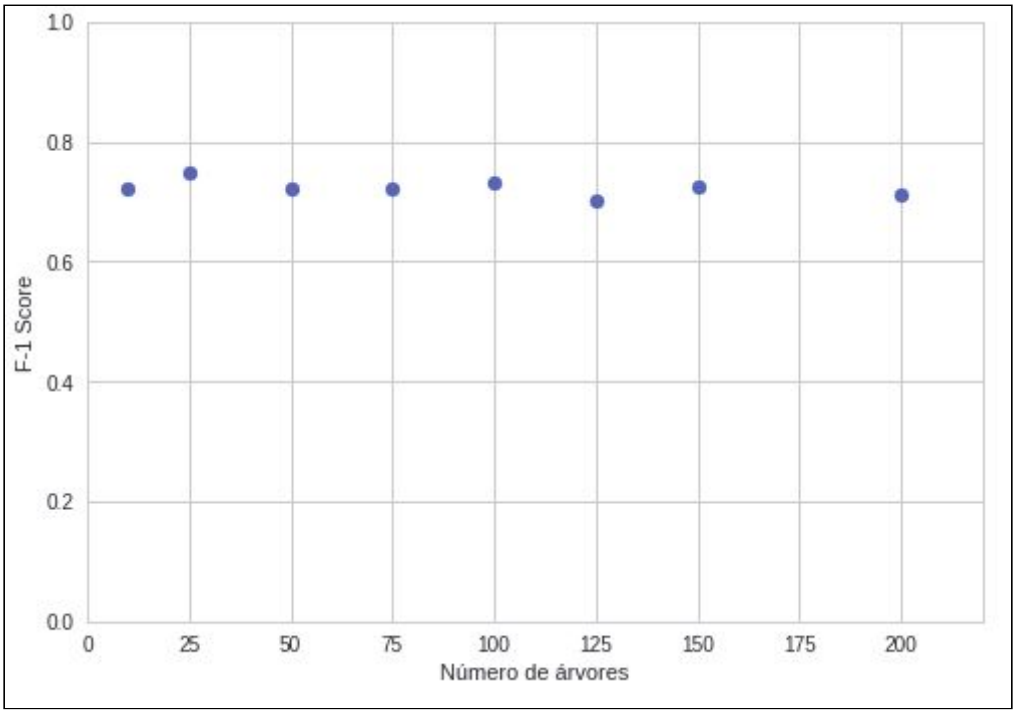

O desempenho do algoritmo para esse conjunto de dados variou muito pouco. Ademais, ele variou em ambas direções, sem seguir uma progressão, portanto não está evidente se a variância de ntree teve alguma relevância estatisticamente ou se as diferenças são apenas efeito da aleatoriedade.

2. Ionosphere

F1 \ Árvores	10	25	50	75	100	125
Média	0.78	0.76	0.80	0.84	0.80	0.76
Desvio	0.05	0.04	0.06	0.07	0.06	0.04

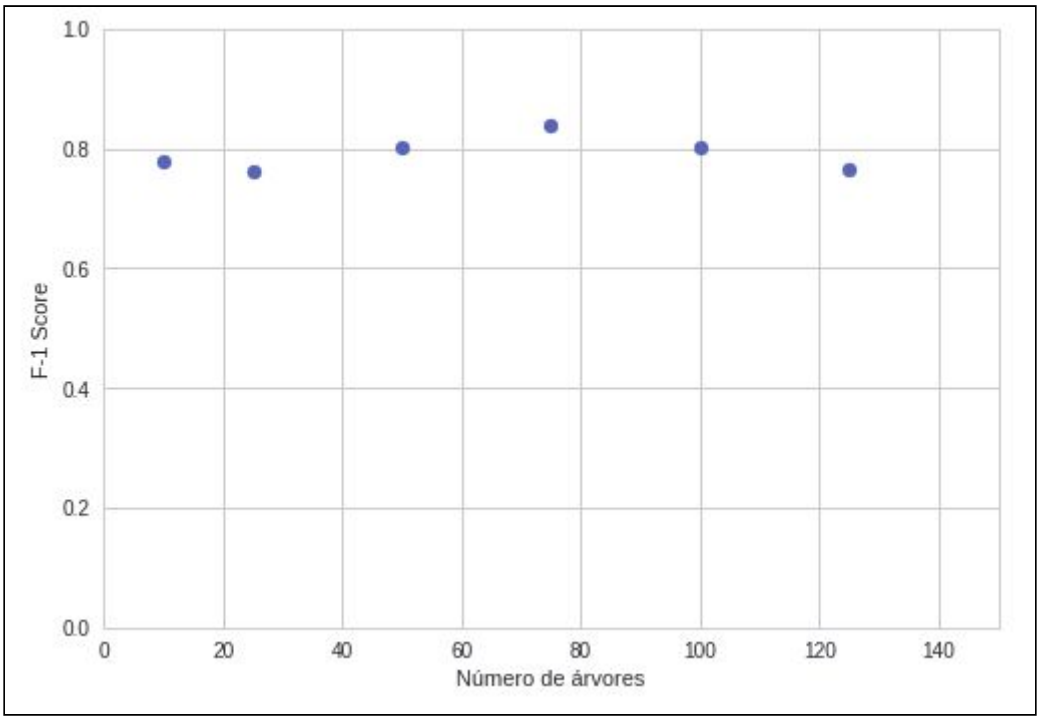

Esse conjunto de dados foi o que apresentou a maior variação. Ele progride de forma relativamente acentuada à medida que *ntree* cresce até 75. No entanto, depois decai.

3. Breast Cancer (Extra)

F1 \ Árvores	**10**	**25**	**50**	**75**	**100**	**125**
Média	0.83	0.87	0.87	0.87	0.86	0.88
Desvio	0.07	0.03	0.04	0.05	0.05	0.05

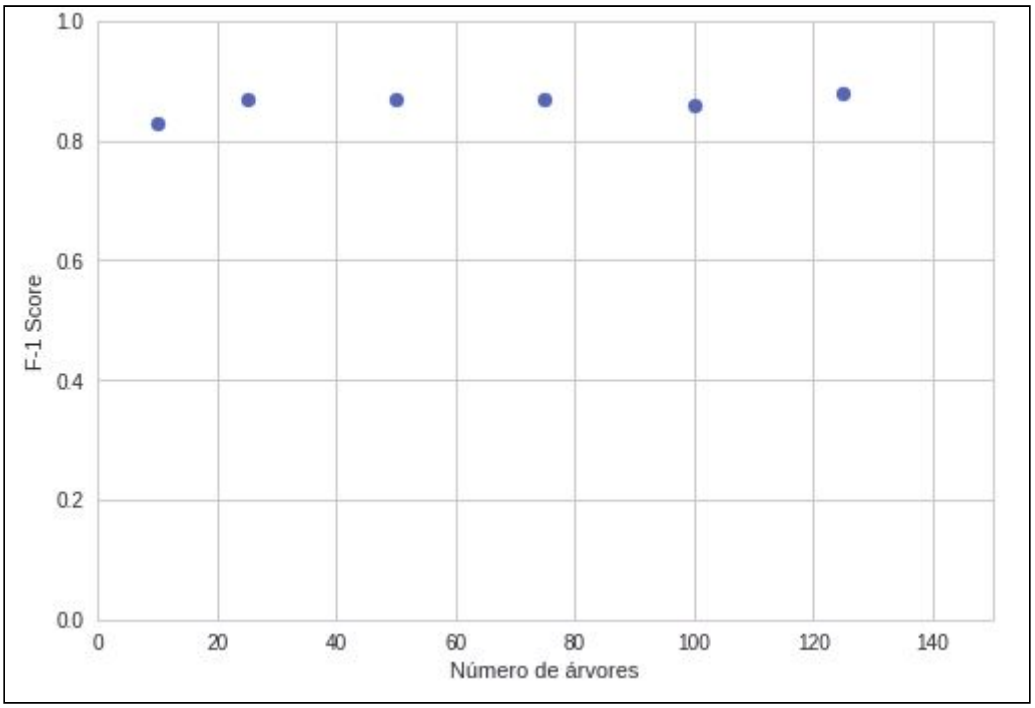

Os resultados para esse conjunto de dados mostram uma progressão contínua, apesar de pequena.

4. Wine

prec_macro \ Árvores	**10**	**25**	**50**	**75**	**100**	**125**
Média	0.94	0.93	0.94	0.92	0.94	0.94
Desvio	0.06	0.07	0.04	0.06	0.04	0.07

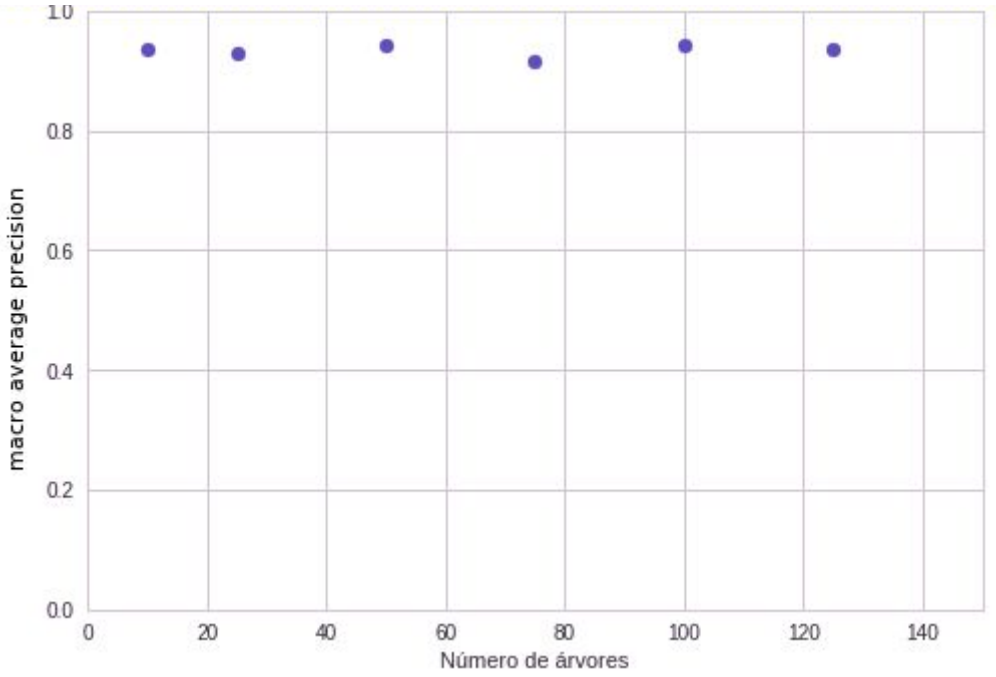

Esse conjunto de dados foi o que apresentou a melhor métrica. No entanto, varia muito pouco com as variações de *ntree.*

Conclusão

Teoricamente, à medida que *ntree* cresce o erro deve diminuir e, consequentemente, a média de acertos aumentar. No entanto, no geral, isso não ficou muito nítido nos resultados obtidos.

Ademais, as variações nas métricas foram muito pequenas, a ponto de não se entender o quanto elas são efeito da variância do parâmetro ou se ocorrem na maior parcela devido à aleatoriedade do algoritmo. Também, por conta disso, não ficou evidente se essas diferenças são estatisticamente relevantes.

Esperávamos encontrar uma diferença maior nos resultados. Independente disso, realizar esse trabalho foi bastante interessante e também importante, pois contribuiu para compreendermos mais a fundo vários conteúdos vistos em sala de aula.